

Bachelorarbeit

**Optimierung von logistischer Regression auf  
FPGAs**

Moritz Sliwinski  
Februar 2020

Gutachter:

Prof. Dr. Katharina Morik

Sebastian Buschjäger

Technische Universität Dortmund

Fakultät für Informatik

Lehrstuhl für Künstliche Intelligenz (LS-8)

<https://www-ai.cs.tu-dortmund.de>



# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>1</b>
1.1	Motivation und Hintergrund . . . . .	1
1.2	Aufbau der Arbeit . . . . .	1
<b>2</b>	<b>FPGAs</b>	<b>3</b>
2.1	Allgemeiner Aufbau von FPGAs . . . . .	3
2.2	Konfiguration und Ablauf . . . . .	4
2.3	Verwendete Hardware . . . . .	6
2.4	Verwendete Software . . . . .	7
<b>3</b>	<b>Logistische Regression</b>	<b>9</b>
3.1	Definition und Funktion . . . . .	9
3.2	Geschichte und Entwicklung . . . . .	11
3.3	Regularisierungsmethoden . . . . .	11
3.3.1	LASSO . . . . .	11
3.3.2	Ridge Regression . . . . .	11
3.4	Grenzen . . . . .	11
3.5	Verwandte Algorithmen . . . . .	11
<b>A</b>	<b>Weitere Informationen</b>	<b>13</b>
	<b>Abbildungsverzeichnis</b>	<b>15</b>
	<b>Literaturverzeichnis</b>	<b>17</b>
	<b>Erklärung</b>	<b>17</b>



# Kapitel 1

## Einleitung

### 1.1 Motivation und Hintergrund

Maschinelles Lernen und Vorhersagen werden immer mehr in unser Leben integriert. Hierbei entsteht zum einen der Anspruch an variable, nicht statische Systeme, zum anderen die Notwendigkeit kompakter und energieeffizienter Lösungen.

Aufgrund der immer weiter wachsenden Datenmengen stoßen herkömmliche Central Processing Units (CPUs) mittlerweile an Ihre Grenzen, denn durch materialbedingte Limitierung kann ihre Rechenkapazität so gut wie nicht mehr erhöht werden. Daher geht man dazu über, Mehrkernprozessoren zu entwickeln, die ihre Geschwindigkeit über parallele Threads erreichen. Diese haben jedoch einen vergleichsweise hohen Energieverbrauch.

Field Programmable Gate Arrays (FPGAs) bieten in diesem Zusammenhang einen guten Kompromiss zwischen Flexibilität in der Programmierbarkeit und Energieeffizienz. Der Vorteil der FPGAs zeigt sich in der deutlich höheren Parallelität gegenüber CPUs, sodass trotz der geringeren Taktfrequenz eine große Menge an Daten schnell verarbeitet werden kann.

Die logistische Regression ist für die Optimierung auf FPGAs in dem Sinne gut geeignet, da sie eine einfache Art von neuronalem Netz darstellt und somit gut in der FPGA-Logik darstellbar ist. Sie weist zum Beispiel durch Datenparallelität bzw. Parallelisierung von Batches, Feature- oder Hyperparameter-Berechnung eine hohe Parallelisierbarkeit auf.

Moderne FPGAs können über die PCIe-Schnittstelle als CO-Prozessor in ein System eingebunden werden, sodass deren Parallelität und Energieeffizienz ausgenutzt werden können. Dank des hohen Durchsatzes der Schnittstelle muss hierbei nicht auf eine komplexe variable Vorbereitung der Daten durch die CPU im laufenden Betrieb verzichtet werden.

### 1.2 Aufbau der Arbeit



# Kapitel 2

## FPGAs


Die Arbeit befasst sich mit der Implementierung und Optimierung von Logistischer Regression auf FPGAs. Deshalb wird zunächst der allgemeine Aufbau dieser beschrieben. Dann folgt eine Einführung in die Konfiguration des FPGAs, wobei zum einen auf den typischen Ablauf, zum anderen auf die verwendeten Programme eingegangen wird. Abschließend wird die verwendete Hard- und Software aufgeführt.

### 2.1 Allgemeiner Aufbau von FPGAs


Field Programmable Gate Arrays (FPGAs) sind Integrierte Schaltkreise (IC), in die eine logische Schaltung programmiert werden kann. Die ICs bestehen aus I/O-Blöcken, programmierbaren Logikblöcken (CLP) und weiteren Bestandteilen (wie zum Beispiel DSP-Slices, BRAM-Blöcken, Multipliziereinheiten oder Taktgeneratoren) welche durch Datenpfade zu einer Matrix miteinander verbunden sind (Siehe Abbildung 2.1).

Die Pfade können je nach Bedarf geschaltet werden. Die CLPs selbst bestehen aus einem 1 Bit Flip-Flop und einer programmierbaren Wahrheitstabelle. Über diese lassen sich die logischen Funktionen konfigurieren.[2] Ein schematischer Aufbau ist in Abbildung 2.2 zu sehen. Dieser Aufbau ist typisch für ein FPGA der Marke Xilinx und nicht allgemein für andere Hersteller gültig. Da in dieser Arbeit (wie in Kapitel 2.3 beschrieben) ein FPGA der Marke Xilinx benutzt wird, wird auch dessen Hardwarekonfiguration zugrunde gelegt.

Die Programmierung ist in diesem Fall vergleichbar mit einer Schalttabelle, welche bestimmt wie die physikalischen Bausteine miteinander verbunden werden sollen. Anders als bei Application-Specific Integrated Circuits (ASICs), dessen Funktion bereits bei der Produktion festgelegt werden, können FPGAs vom Benutzer selbst (Re)Konfiguriert werden.



**Abbildung 2.1:** Aufbau eines IC, die grauen Schaltblöcke (SB) sind die konfigurierbaren Datenpfade



**Abbildung 2.2:** Schematische Darstellung eines CLP

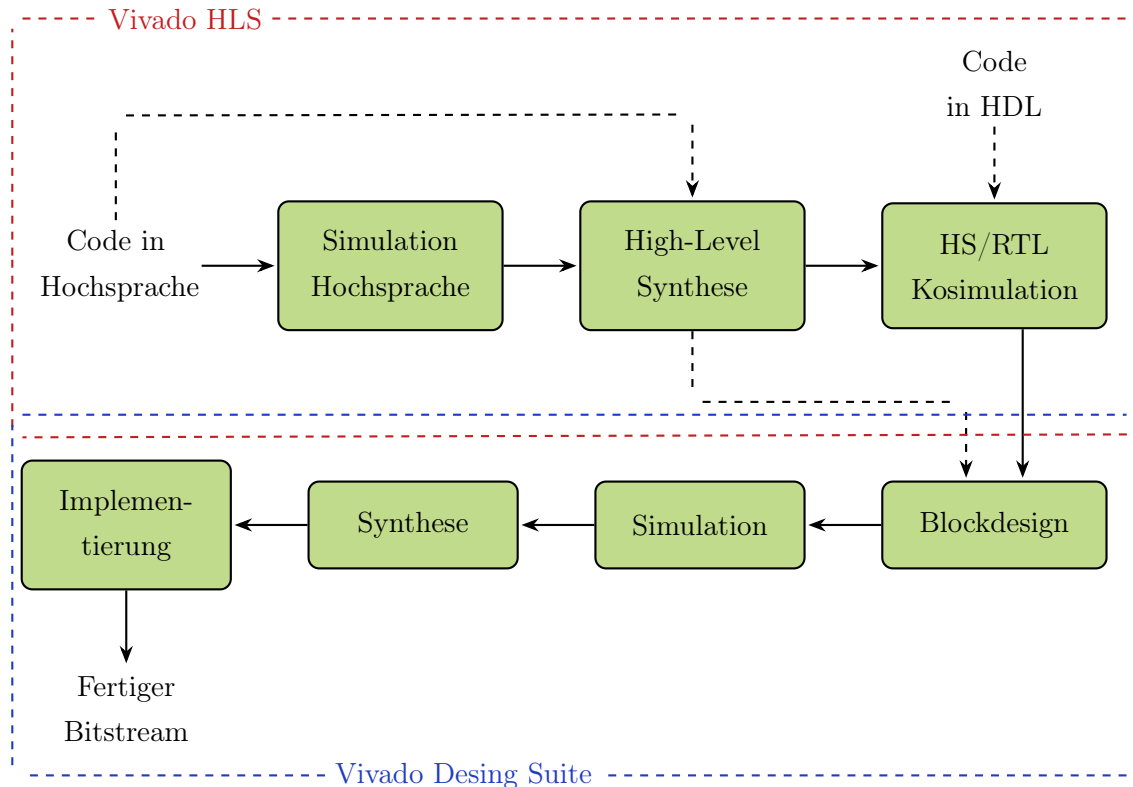
Dies geschieht jedoch im Gegensatz zu Mikroprozessoren nicht während, sondern vor Inbetriebnahme des Chips. Zwar ist es bei einigen wenigen Herstellern von FPGAs mittlerweile möglich, diese auch während des laufenden Betriebs zu konfigurieren (partielle Rekonfiguration), was jedoch mit einer höheren Komplexität der zu konfigurierenden Logik verbunden ist.

Durch die Konfigurierbarkeit des FPGAs ergeben sich allerdings einige Nachteile gegenüber den ASICs. FPGAs sind annäherungsweise 20 bis 35 mal größer und zwischen 3 und 4 mal langsamer als eine vergleichbare ASIC Implementierung. Außerdem verbrauchen sie dynamisch circa 10 mal mehr Energie. [6] Damit sind sie deutlich ineffizienter als ASICs. Der große Vorteil ergibt sich hier aus der Konfigurierbarkeit, denn ASICs sind nach der Produktion nicht mehr veränderbar. Gerade in Bereichen die eine hohe Flexibilität verlangen ist es vor allem Kosteneffizienter FPGAs zu benutzen, denn die Produktion von ASICs ist mit großen zeitlichen und finanziellen Investitionen verbunden.[5]

## 2.2 Konfiguration und Ablauf

Wie das „Field Programmable“ schon vermuten lässt, ist es möglich nach der Fabrikation des FPGA Funktionen in diese zu programmieren („in the field“). [5] um diese Funktion zu verändern muss das FPGA neu Konfiguriert werden. Dies geschieht durch einen sogenannten „Bitstream“, eine Sequenz von einzelnen Bits. In Abbildung 2.3 zeigt sich der Ablauf zur Generierung eines solchen Bitstreams für ein FPGA der Marke Xilinx.





**Abbildung 2.3:** Konfigurationsablauf eines Xilinx-FPGAs

Zunächst programmiert man die geplante Anwendung/Funktion in einer beliebigen Hochsprache, zum Beispiel BSV in Bluespec oder MaxJ in MaxCompiler. Die am häufigsten verwendete Sprache ist jedoch C oder C++, wie auch in diesem Fall mit Vivado HLS.[7]

Dann folgt eine Simulation des Programms um dessen Tauglichkeit für eine FPGA Konfiguration zu prüfen. Dieser Schritt ist optional, jedoch sehr hilfreich, denn die High-Level Synthese von Vivado HLS unterstützt nicht alle Besonderheiten und Datentypen von C++. Es können zum Beispiel keine Arrays mit variabler (zur Laufzeit definierter) Länge instanziiert oder Rekursive Funktionen verwendet werden. Außerdem werden Anfragen an das System nicht unterstützt und die Hauptfunktion muss die gesamte Funktionalität des Designs enthalten.[10]

Nun wird mit Der High-Level Synthese ein Programm in einer HDL (Hardware Definition Language, in diesem Fall VHDL oder Verilog) erstellt. Es ist auch möglich die RTL (Register Transfer Level) mit einer HDL selbst zu programmieren. Dieser Ansatz kann zu deutlich effizienteren Designs führen, ist aber auch mit erheblichem Mehraufwand verbunden. Vor allem der geringere Programmieraufwand gegenüber einem nicht signifikantem Leistungsverlust ist ausschlaggebend dafür, dass dieser Ansatz in der Arbeit nicht weiter behandelt wird, jedoch einen Ausblick auf weitere Verbesserungsmöglichkeiten bietet.

Man kann nun die Hochsprache und die RTL nebeneinander (ko-) simulieren, um das Verhalten der HLS zu verifizieren. Auch dieser Schritt ist optional und dient der frühen Fehlerfindung.

Nach diesem Schritt wird das RTL-Design als IP (Intellectual Property) exportiert und mit der Vivado Design Suite von Xilinx weiter bearbeitet. Zusammen mit IP-Blöcken von Xilinx und Drittanbietern erstellt man nun ein funktionstüchtiges Design, indem man die Ein- und Ausgänge der Blöcke sinnvoll miteinander verknüpft. Das erstellte Projekt geht jetzt in den Simulationsschritt, bei dem das echte Verhalten des FPGA emuliert werden soll der Kontrolle der Funktionalität dienen. Im darauffolgenden Syntheseschritt wird durch die Software ein Schaltplan der Funktion erstellt, der die Hardwareprogrammierung auf einem theoretischen FPGA (mit unbegrenzten Hardwarebausteinen) darstellt. Hierbei werden erste Berichte zu der Ressourcenauslastung, dem Timing und dem Energieverbrauch erstellt. Diese sind allerdings nur Schätzungen und dienen dem Auffinden von groben Fehlern, zum Beispiel wenn mehr Ressourcen verbraucht werden würden als das FPGA hat.

Im Implementierungsschritt werden nun der vorhandene Netzplan auf das spezifizierte FPGA angewendet und konkrete Vernetzungen errechnet. Die dabei erstellten Berichte sind nun genau, sodass etwaige Fehler nun korrekt behoben werden können. Man kann nun auch einen Schaltplan des FPGA einsehen, in dem alle tatsächlich verwendeten Bausteine markiert sind. Aus dem implementierten Design kann nun der Bitstream erstellt werden, mit dem der FPGA dann programmiert wird.

## 2.3 Verwendete Hardware

Das in dieser Arbeit verwendete Board ist ein AC701 Evaluation Kit der Firma Xilinx Inc. Darauf enthalten ist ein FPGA der Serie Artix-7, genauer XC7A200T-2FBG676C. Dieses enthält 215.360 Logikzellen, 740 DSP48E1 (Digital Signal Processor) Slices, 13.140 Kb Block RAM, 33.650 CLB (Configurable Logic Blocks) Slices und 500 I/O Pins.[9]

Des Weiteren sind auf dem Board unter anderem 1GB DDR3 RAM Speicher, 256 Mb Flash Speicher, ein SD (Secure Digital) Connector, Mehrere Clock Generatoren (zum Beispiel ein Fixed 200 MHz LVDS oscillator), Status LEDs und konfigurierbare Schalter verbaut.

Als Kommunikationsschnittstellen stehen jeweils eine Gen1 4-Lane (x4) und eine Gen2 4-Lane (x4) PCI Express Schnittstelle, ein SFP+ (Enhanced Small Form-factor Pluggable) Connector, ein HDMI (High Definition Multimedia Interface) Ausgang, UART (USB zu Universal Asynchronous Receiver Transmitter) Brücke und eine 10/100/1000 MBit/s tri-speed Ethernet PHY (Physikalische Schnittstelle) zur Verfügung.[11]

Eingebaut ist das Board in einen Desktop-PC einem Intel Xenon W3565 Prozessor und 24 GB DDR3 RAM, welcher unter Ubuntu 14.04.5 LTS 64-Bit betrieben wird. Das Board ist über die UART Schnittstelle mit einem USB-Ausgang dieses Rechners verbunden und wird darüber konfiguriert. Das Erstellen der Software und der Bitstreams erfolgt über einen Desktop PC mit einer AMD Phenom<sup>TM</sup> II X4 960T CPU und 8 GB DDR3 RAM.

## 2.4 Verwendete Software

Für die High Level Synthese und die Generierung des Bitstreams werden Vivado HLS und die Vivado Design Suite von Xilinx verwendet. Die Kommunikation mit dem FPGA und dem Host-Rechner erfolgt über PCIe mit einem IP-Core von Xillybus.[1] Die Arbeit baut in dieser Hinsicht auf „Umsetzung einer High-Performance FPGA-Schnittstelle für maschinelles Lernen“ von Dillkötter[4] auf. Die entworfenen Bitstreams werden über den Hardware-Manager von Xilinx auf das FPGA geladen, sodass mit dem Hostrechner nur über SSH (Secure Shell) gearbeitet wird.



# Kapitel 3

## Logistische Regression

Dieses Kapitel befasst sich mit der Logistischen Regression. Zunächst wird die Definition und Funktion der Logistischen Regression erklärt. Danach wird die Geschichte und Entwicklung der Methode erörtert. Des weiteren gibt es eine Vertiefung der verschiedenen Regularisierungsmethoden und zum Abschluss die Grenzen der Funktion sowie einen Ausblick auf verwandte Algorithmen.

### 3.1 Definition und Funktion

Die logistische Regression ist ein statistisches Analyseverfahren, bei dem es darum geht, eine Beziehung zwischen einer abhängigen und mehrerer unabhängiger Variablen zu modellieren und wird auch als binäres Logit-Modell bezeichnet. Sie unterscheidet sich in soweit von der linearen Regression, dass die Voraussagen nicht spezielle Werte, sondern die Wahrscheinlichkeiten angeben, mit denen die jeweilige Ausprägung der Variable angenommen wird.[8] Die beiden Ausprägungen der abhängigen Variablen wird mit 0 bzw. 1 beschrieben, sodass die Vorhersage des Modells die Wahrscheinlichkeit beschreibt, mit der die abhängige Variable den Wert 1 annimmt, formal  $P(Y_i = 1)$ . Die Logistische Regression gehört zur Klasse der strukturen-prüfenden Verfahren und bildet eine Variation der Regressionsanalyse. Sie grenzt sich durch die Art ihrer abhängigen Variable, bezeichnet mit  $Y$ , welche als kategoriale Variable klassifiziert ist, von anderen Regressionsanalysen ab. Die Ausprägungen der Variable repräsentieren die verschiedenen Alternativen, in unserem binären (oder auch dichotomen) Fall ist „trifft zu“ und „trifft nicht zu“.[3] Diese Gruppen werden nun mit 0 und 1 bezeichnet und für die  $Y$  Variable gilt nun:


$$P(Y = 0) = 1 - P(Y = 1) \text{ und } P(Y = 1) = 1 - P(Y = 0)$$

Ausdrücken lässt sich das logistische Regressionsmodell nun wie folgt:

$$\pi(x) = f(x_i, \dots, x_i)$$

Wobei  $\pi(x) = P(Y = 1|x)$  die bedingte Wahrscheinlichkeit, unter der das Ereignis 1 („trifft zu“) mit den gegebenen Werten  $x = (x_1, \dots, x_i)^T$  eintritt, angibt.

Ziele der logistischen Regression ist es, gegeben Trainingsdaten  $D = \{(x_1, y_1), \dots, (x_N, y_N)\}$



**Abbildung 3.1:** Die logistische Funktion  $p = \frac{1}{1 + e^{-x}}$

mit  $x_i \in \mathbb{R}^d$  und  $y_i \in \{0, 1\}$ , ein Modell  $f_\beta(x)$  für Vorhersagen finden, welches auf neuen, ungesehenen Daten einen möglichst kleinen Fehler macht.

Das binomiale logistische Regressionsmodell ist wie folgt beschrieben:

$$P(Y = 1|X = x_i) = P(Y_i = 1) = \frac{\exp(\beta_0 + x_i^T \beta)}{1 + \exp(\beta_0 + x_i^T \beta)} = \frac{1}{1 + \exp(-(\beta_0 + x_i^T \beta))}$$

$\beta$  stellt hier den Vektor der Koeffizienten  $(\beta_1, \dots, \beta_n)^T$  dar und  $\beta_0$  ist der Bias.

Die Anpassung der Koeffizienten erfolgt durch Minimierung der Loss Funktion:

$$\min_{\beta} \sum_i^N \log(1 + \exp(-(\beta_0 + x_i^T \beta))) + C * R(\beta)$$

Wobei  $C \in \mathbb{R}$  ein Hyperparameter ist, der fest gewählt werden muss. Dies geschieht zumeist durch das Testen verschiedener Werte, sodass hier ein Ansatz zur Parallelisierung entsteht.

## 3.2 Geschichte und Entwicklung

## 3.3 Regularisierungsmethoden

### 3.3.1 LASSO

L1-Regularisierung (Least Absolute Shrinkage and Selection Operator, kurz **LASSO**) mit  $R(\beta) = \sum_i^N |\beta_i|$

### 3.3.2 Ridge Regression

L2-Regularisierung (Ridge Regression) mit  $R(\beta) = \sum_i^N \beta_i^2$ .

## 3.4 Grenzen

## 3.5 Verwandte Algorithmen





Anhang A

Weitere Informationen



# Abbildungsverzeichnis

2.1	Aufbau eines IC, die grauen Schaltblöcke (SB) sind die konfigurierbaren Datenpfade . . . . .	4
2.2	Schematische Darstellung eines CLP . . . . .	4
2.3	Konfigurationsablauf eines Xilinx-FPGAs . . . . .	5
3.1	Die logistische Funktion $p = \frac{1}{1 + e^{-x}}$ . . . . .	10



# Literaturverzeichnis

- [1] *An FPGA IP core for easy DMA over PCIe with Windows and Linux*. <http://xillybus.com/>. Besucht: 10.12.2019.
- [2] AMAGASAKI, MOTOKI und YUICHIRO SHIBATA: *Principles and Structures of FPGAs: FPGA Structure*. Springer Nature Singapore Pte Ltd., Seiten 23–45, 2018.
- [3] BECKHAUS, K., B. ERICHSON, W. PLINKE und R. WEIBER: *Logistische Regression*, Band 14. Springer Gabler, Berlin, Heidelberg, 2016.
- [4] DILLKÖTTER, FABIAN: *Umsetzung einer High-Performance FPGA-Schnittstelle für maschinelles Lernen*, 2019.
- [5] KUON, I., R. TESSIER und J. ROSE: *FPGA Architecture: Survey and Challenges*. now, 2008.
- [6] KUON, IAN und JONATHAN ROSE: *Measuring the Gap Between FPGAs and ASICs*. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 26:203–215, 2007.
- [7] NANE, R., V. SIMA, C. PILATO, J. CHOI, B. FORT, A. CANIS, Y. T. CHEN, H. HSIAO, S. BROWN, F. FERRANDI, J. ANDERSON und K. BERTELS: *A Survey and Evaluation of FPGA High-Level Synthesis Tools*. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 35(10):1591–1604, Oct 2016.
- [8] ROHRLACK, C.: *Logistische und Ordinale Regression*, Band 3. Gabler Verlag, Wiesbaden, 2009.
- [9] XILINX: *7 Series FPGAs Data Sheet: Overview*. 2018.
- [10] XILINX: *Vivado Design Suite User Guide High-Level Synthesis*. 2018.
- [11] XILINX: *AC701 Evaluation Board for the Artix-7 FPGA*. 2019.



Hiermit versichere ich, dass ich die vorliegende Arbeit selbstständig verfasst habe und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet sowie Zitate kenntlich gemacht habe.

Dortmund, den 22. Januar 2020

Muster Mustermann

